

ログノート：時間削減率の評価

Anonymous

概要

収集した情報、解析結果・知見、ログ情報など研究過程を収録した研究ログノート。論文に記載していない詳細を含んでいる。

【version 履歴】

- 1 記録終了 2026.5.13
- 2 データ公開アドレス記入 2026.9.9

目次

0	背景：測定実験の歴史	1
1	職業真値の構成	2
1.1	職業記述書とタスク属性	2
1.2	ベンチマーク削減率 BM/ref4	3
2	導入：生産性の見積問題	3
2.1	Introduction	3
2.2	Related Work	3
3	Problem Setting and Data	4
3.1	タスク設定	4
3.2	モデル出力と時間短縮率の推定	4
3.3	重要度ウェイトとタスク／職種の集約	4
3.4	Segment 仮説	5
3.5	交互作用 (職業真値参照)	5
4	参照値と誤差の定義	6
4.1	条件付き量としての参照値	6
4.2	職種参照値 (occupation-truth) に基づく誤差	7
4.3	タスク参照値に基づく誤差 (主要指標)	7
5	タスク真値 (Task-Truth) 分解	7
5.1	動機 (Motivation)	7
5.2	線形混合モデル (Linear Mixing Model)	7
5.3	分解の品質と限界	7
6	Results	7
6.1	R1. タスク真値ベースでも、見積スタイル (A/B/C) の差が支配的である	7
6.2	R2. 理由文 proxy は保守性と整合し、タスク・セグメントを制御しても残る	8

6.3	R3. 重要度タスク交互作用は、タスク真値ベースでは強くは出ない	8
7	Discussion	9
8	制限事項: Limitations	9
9	Conclusion	10
付録 A	職種参照値 (Occupation-Truth) とタスク参照値 (Task-Truth) の比較	10
A.1	職種真値 (occupation-truth) に基づくベータスライン回帰	10
A.2	タスク真値 (task-truth) 分解の詳細	12
付録 B	プロキシ構築と感度分析	13
B.1	キーワード辞書と正規化	13
B.2	欠損に対する感度分析 (Missingness sensitivity analyses)	13
B.3	プロキシ変数の説明力	13
付録 C	職業データとモデル一覧	14
C.1	職業データ一覧	14
C.2	使用したモデル一覧	14
C.3	職業真値からの誤差	14
C.4	モデルごとの時間削減率	15
付録 D	資料	17

0 背景：測定実験の歴史

生成 AI を利用して業務がどれだけ改善したかを表現する指標の一つに時間削減率がある。これに関する検証報告がいくつかある [1]-[7]。実際の業務で AI 活用して、どれくらい削減効果があるのかを実験により評価した例は少ない。AI に削減率を見積もってもらう場合の正解データ（真値）として参照する価値があるので、これらの内容を以下におさらいしておく。

ref.[1] この研究では、Trane Technologies 社が開発した GPT-3.5 ベースの社内ツールを使用する「テストグループ」と、手動で作業を行う「コントロールグループ」を比較し、文書作成業務に関わる主要タスクの時間削減率を計測した。

タスクの性質による差：大量のテキストを処理したりワーキングメモリへの負荷が高いタスク（要約など）では、AI による生産性向上が劇的（69%）である一方、比較的単純なタスク（メール作成）では、プロンプトの作成や AI の回答確認・編集に時間がかかるため、手動作成と比べて大きな時間短縮にはつながらない（3.3%）ことが示された。

主要 3 タスクの削減率：記事の要約：69%、指示書の作成：45%、プレゼン資料の作成：25%

ref.[2] この研究では、特定の職種における「中レベルのプロフェッショナルな執筆タスク（mid-level professional writing tasks）」が検証対象。検証時期から使用した ChatGPT は GPT3.5 と考えられる。(1) 対象者：444 名の経験豊富な専門職（大卒者）(2) 対象職種：マーケティング担当者、助成金申請ライター、コンサルタント、データアナリスト、人事（HR）専門家、マネージャー。(3) 具体的なタスク例：プレスリリースの執筆、短いレポートの作成、分析計画書の作成、慎重を要するメール（delicate emails）の作成など。

結果：コントロール群が平均 27 分かかったのに対し、AI 利用群は平均 17 分で完了し、約 37%（10 分） $(27-17)/27=0.37$ の時間短縮を実現。

ref.[3] この研究では、韓国の大手企業（Company S）における「企業の財務経費処理プロセス（Corporate Financial Expense Processing）」が検証対象。プロセスの内訳は、(1). 領収書の処理：従業員が提出した法人カードの領収書（紙や画像の非構造化データ）の読み取り。(2). 情報の抽出：IDP（Intelligent Document Processing）を用いて、日付、金額、品目などの主要情報を抽出する。(3). ポリシーに基づく分類：抽出された品目が社内規定（ホワイトリスト/ブラックリスト）に適合するか、どの勘定科目に該当するかを判定する。(4). 例外処理（重要）：新製品や分類が曖昧な品目について、生成 AI（LLM）を用いて社内ポリシー文書に基づいた適切な判断・推奨を行う。

結果：全体の処理時間は 80%-90% 削減された。この改善は、単なる定型業務の自動化（RPA）にとどまらず、従来は人間が判断しなければならなかった「例外的な状況（未登録の品目など）」に対して、生成 AI がポリシー文書を読み込んで判断根拠と推奨勘定科目を提示できるよう

になった点が大きく寄与している。GPT3.5 から性能向上した GPT-4o-mini を利用している点が高い。（Samsung SDS 社の自動化プラットフォーム「Brity Automation」を使用しており、その機能である「AI Flow」の中で、OpenAI の API（GPT-4o mini）を呼び出して経費品目の分類や例外判定を行っている。）

ref.[4] このレポートは、従来の実験室での管理されたテストとは異なり、実際のユーザーと Claude の間で行われた 10 万件の会話ログを分析し、AI がタスク完了時間をどれだけ短縮したかを推定した。Claude 自身が「人間が手動で行った場合の推定時間」と「AI との対話にかかった時間」を比較して推計値を算出している：According to an internal productivity analysis by Anthropic, analysis of 100,000 real-world AI-assisted task interactions suggests that task completion time was reduced by an estimated around 80% on average when assisted by AI, based on anonymized usage logs (Anthropic, 2025).[4]

結果概要（削減率ごとのタスク）：

(1). 高い効果が確認されたタスク（90% 以上の短縮）

AI の「読み書きの速さ」や「情報整理能力」が活きるタスクで劇的な効果が出ている。

・教育カリキュラムの作成 (96%): 職業教育教師が指導計画やコース内容を作成するタスク。

・レポート情報の編集 (95%): 複数のレポートから情報を抽出・統合するタスク。

・リサーチ結果のまとめ (91%): 社会科学リサーチアシスタントが表、グラフ、ファクトシートを作成し、結果を要約するタスク。

(2). 中～高程度の効果が確認されたタスク（70～89% の短縮）

一般的なビジネス文書作成や分析業務が含まれる。

・事務書類の作成 (87%): 秘書業務として、請求書、レポート、メモ、財務諸表などを作成するタスク。

・財務分析 (80%): アナリストが価格、利回り、投資リスクなどのデータを解釈するタスク。

・学生へのアドバイス (83%): 農学教師が学生の進路やカリキュラムについて助言するタスク。

(3). 比較的效果が低かったタスク（60% 以下の短縮）

物理的な確認が必要なものや、専門家がすでに素早く行えるタスクでは効果が限定的。

・事務機器のトラブルシューティング (56%): コンピューターハードウェアやソフトの問題解決。

職種別の傾向では、マネジメント（85.1%）、ビジネス・財務（83.5%）、法務（80.7%）、エンジニアリング（77.7%）など、賃金の高い複雑なナレッジワークにおいて高い時間短縮効果が見られた。一方で、販売（66.2%）や設置・修理（65.7%）などは相対的に低い結果となった。

ref.[6] この研究は、生成 AI の経済的インパクトを、実際の職場環境（フィールド）で大規模に検証した最初期の重要な研究の一つである。検証対象となったタスク：フォーチュン 500 に含まれる企業向けソフトウェア会社のカスタマーサポート（テクニカルサポート）部門。結果：1 件当たりの処理時間で 9% 削減。複数チャットの同時処理能力と

して 14% 削減。検証実施時期から推定で、GPT3 を使用。
ref.[7] 納税者向けバーチャルアシスタント（シンガポール内国歳入庁 - IRAS）を用いて、納税者からの一般的な問い合わせへの自動回答（「AskJamie」およびその後の GenAI 活用）。回答時間を最大 80% 短縮した。

1 職業真値の構成

ref.[1] の検証対象となった主要 3 タスクを抽象化すると、文章を扱い、情報を整理し、相手に伝わる形に再構成することが中心的な仕事となる。（主要 3 タスク：文書要約 T_1 、指示書の作成 T_2 、プレゼン資料作成 T_3 ）

この特徴をもつ典型的な職業を考えると：

1. コンサルタント系

例：経営コンサルタント、IT コンサルタント、業務改善コンサルタント、戦略アナリスト。

特徴：クライアントの情報を要約し、指示書（To-Be プロセス、要件定義）を作り、プレゼン資料を作るのが日常業務。

2. 企画・マーケティング職

例：企画職（事業企画・商品企画）、マーケティング担当、広報・PR 担当。

特徴：社内外向けの資料作成が多い。市場調査の要約、企画書・指示書の作成、社内プレゼン資料の作成が必須スキル。

3. プロジェクトマネージャー（PM）／プロダクトマネージャー（PdM）

例：IT プロジェクトマネージャー、プロダクトマネージャー。

特徴：プロジェクトを動かすための文書作成が多い。要件定義書、タスク指示書、ステークホルダー向けプレゼン資料などを大量に作る。

4. 編集者・ライター・リサーチャー

例：編集者（出版社・Web メディア）、リサーチャー、テクニカルライター。

特徴：文章の要約と構成が中心。記事の要約、構成案、資料化が日常業務。

5. 事務・アシスタント職

例：営業アシスタント、秘書、総務・管理部門。

特徴：社内文書の整理・作成が多い。議事録、要約、指示書、社内説明資料などを作成。

6. 教育・研修系の職種

例：研修講師、インストラクショナルデザイナー、企業内トレーナー。

特徴：教材要約、手順書作成、研修用プレゼン資料作成が中心。

ref.[2] の検証対象を一般化すると、上記職業群の 1,2,3,4 が該当する。手に入れた情報を要約 T_1 、条件ルールやフォーマットに基づく処理 T_2 、結果の報告・提示 T_3 というフロー構造は、文書作成に特化していなくても、インプット、処理、アウトプットという共通の業務フレームワークに従っている。上記以外の職業を他の文献から拾うと、財務・法務系の職業 [3, 4] と、カスタマーサポート [4, 6, 7]

などの職業がある。これらの実績値とタスクの特徴を以下に整理しておく。

財務経理系の実績値には、ref.[3](80-90%) 以外にも、ref.[4] に財務分析 (80%)、ビジネス・財務 (83.5%)、法務 (80.7%) などが記載されている。本稿では平均的に 80% としておく。

カスタマーサポート系の実績値：ref.[7]（納税者対応）で 80%、ref.[4] 事務機器のトラブルシューティング (56%) がある。（ref.[6](9%) は古い GPT3 なので除外）

7. 財務・経理系の職業

特徴：従業員から提出された大量の領収書を精査し、社内規定（ポリシー）に適合しているかを確認・分類し、会計システム（ERP）へ承認・登録するのが日常業務。

例：財務マネージャー、経理担当スタッフ、経費精算管理者、企業財務オフィサー

主要タスク：

T_1 ：問い合わせ・ログの要約と論点整理（領収書の処理・情報抽出）

T_2 ：ポリシー適合性の審査と勘定科目分類（規定チェック・仕訳）

T_3 ：例外対応と最終承認（意思決定・システム登録）

8. カスタマーサポート・テクニカルサポート系の職業

特徴：顧客からの技術的な問い合わせに対し、チャットシステムを通じてリアルタイムに診断・解決策を提供するのが日常業務。例：テクニカルサポートエージェント、ヘルプデスク担当、カスタマーサクセス担当、チャットサポートオペレーター

主要タスク：

T_1 ：顧客の問題診断と情報収集（ヒアリング・状況把握）

T_2 ：解決策の提案と回答作成（ソリューション提供）

T_3 ：ナレッジの蓄積と学習（組織的な知見共有）

1.1 職業記述書とタスク属性

以上 8 の職業群について、それぞれの業務概要と該当する職業の例、主要 3 タスクの概要と具体的な作業内容を記載した「職業記述書」を作成する。

同じタスクの内容であっても、その性質は職業ごとに異なるのでそれを特徴づける値としてタスク t の時間構成比率 w_t と重要度 W_t の概念を導入する。職業には様々なタスクがあるため時間構成比率を比較可能な形で求めることは困難なので、本稿では主要 3 タスクの時間比率で定義する。具体的には、職業記述書を参照して、主要 3 タスクごとに、人間がその業務を遂行する場合の所要時間の時間比率（3 タスクの構成比率）と、タスクの重要度を生成 AI に推定させたものを準備しておく（表 23）。

文献 [1] では、タスクの性質に応じて削減効果が異なることが指摘されており、担当者のスキルに応じて削減率は異なる [1, 2]。これらの事情を若干考慮するために、タスク内容を異なるものに派生させた職業記述書も一部用意し、その評価も併せて記載している（職業 id に分岐番号 2 を付したものの (2.2,7.2,8.2) が相当する）。具体的には、2.2

(マーケティング担当) は職業記述書自体は同一のものを
用い、見積を行う際に経営企画・事業企画の要素を除外す
る。7.2(財務・経理系)と8.2(カスタマーサポート系)では、
主要3タスクを文書作成にフォーカスした記述書を作成
した。

職業記述書の作成と、重要度、時間比率の推定には Chat-
GPT5.1 Instant を使用した。使用する AI によりこれらの
記述内容や推定値には違いが生じるが、本稿を通じてこれ
らは所与のものとして固定的に扱うため、違いによる影響
は考慮しないものとする。

1.2 ベンチマーク削減率 BM/ref4

表 23 の ref.1 のコラムには、ref.[1] で得られている主要
3タスクの時間削減率(要約 69%, 指示作成 46%, プレゼ
ン作成 25%)をベースに、それらを各職業の時間比率で加
重平均した値を記載してある。ref.1 と ref.2 は GPT3.5 ク
ラスの結果が主であり、ref.2 の職業 1-4 には、文献 [2] に
基づき削減率 37% を記載してある。削減率は 50% を下る
ものが多く、人間作業が締める割合が大きい。職業 7.8 で
は ref.1 値が記載されていないが、代わりに ref.2 のコラム
に文献 [3, 7] に記載の値 80% を採録した(財務 [3], カスタ
マーサポート [7])。これらは GPT-4o-mini の結果と推定さ
れ([3] には記載あり)、値が少々高めているが、最近
の GPT5 系列に比べて劣るので GPT3.5 の代替値として参
考として扱う。

第3のコラム(ref.4)には [4] から対応する職業の削減
率を記載している。ref.4 は検証時期から Claude3.5 以降の
LLM と考えられ(職業 7.8 の LLM もそれに匹敵する)、推
論能力が GPT3.5 よりも大きく向上しているため削減率も
高い。

BM 値は ref.1,2,4 の平均値(値のない場合は2値平均)で
ある。従って、GPT3.5 を含む平均値である BM は GPT3.5
よりは高い水準になるものの、保守的な値となる。この
BM と ref.4 のコラムをこれから推定する削減率の比較基
準とする。

2 導入：生産性に見積問題

2.1 Introduction

生成 AI の業務導入において重要なのは、タスクを正し
く遂行できるか(品質)に加えて、その導入により人間作
業がどの程度削減されるか(生産性)を事前に見積もれる
ことである。しかし、時間削減率の見積は単純な性能評価
よりも難しい。削減率は「AI が出力した内容」だけで決ま
らず、レビュー・承認・関係者調整・例外処理・再作業と
いった残作業や、組織の運用条件(品質基準、リスク許容、
データ制約)に強く依存するためである。したがって、一
般的な LLM のランキング指標(例：対話性能の総合評価)
[8, 9] が高いことが、そのまま削減率見積の精度に結び付
くとは限らない [10]。

本研究は、LLM が業務の時間削減率をどの程度信頼で
きる形で見積もれるかを、職業横断の共通タスク設計で検
証し、誤差の背後要因を定量的に分解する。11 職業に対し

共通の3タスク(要約 T_1 、指示書作成 T_2 、資料作成 T_3)
を設定し、モデルが見積もった「人間時間」「AI 時間」か
らタスク別削減率を算出する。参照値(いわゆる“真値”)
には、実験ベースのベンチマーク(BM)を採用しつつ、参
照値自体が条件依存の量である点を踏まえ、誤差定義と頑
健性評価を重視する。

本研究の主要な貢献は次の3点である。第1に、モデ
ルの見積誤差には、モデル能力だけでなく「見積スタイル
(Estimation Style)」の差が大きく影響し、モデルを一括で回
帰すると相殺によって構造が見えにくくなることを示す。
第2に、職業レベルの参照値しか得られない状況でも、タ
スク真値を推定する簡易な分解(Task-truth decomposition)
により、タスクレベルで整合的な誤差評価を可能にする。
第3に、モデルが提示する理由文(rationale)から抽出し
た proxy 変数(残作業、スコープ拡張、慎重姿勢)が、よ
り保守的な見積(過大推定の抑制)と整合することを示し、
欠損に対する感度分析でこの結論の頑健性を検証する。

2.2 Related Work

2.2.1 LLM evaluation plat- forms/leaderboards

LLM を評価する研究は増えており、タスク横断的な性
能を集約したベンチマーク群やリーダーボードがよく使わ
れている [8, 9]。これらの指標はモデルの一般的な能力を
示すうえで有用ではあるものの、企業での実運用における
成果とはしばしば弱い関連しか持たない。実際のパフォー
マンスは、ワークフローへの統合方法、制約条件、経験差、
人間による監督といった要因に大きく依存するためである
[1, 6]。最近の評価に関する議論では、単一のベンチマーク
を万能の有用性指標として扱うのではなく、コスト、レイ
テンシ、安全性、生産性など、実際に意思決定で重視される
指標に評価基準を合わせる必要性が強調されている [10]。

2.2.2 生産性の測定と human-in-the-loop (人 間が介在する) ワークフロー

AI の生産性に関する研究では [1, 2, 6, 7]、実際に得られ
る効果は、検証・承認・例外処理・反復作業といった残存
する人間の作業に加え、トレーニング、ツール環境、品質
基準といった組織的要因にも左右されることが指摘されて
いる [2, 6]。職場環境での実証研究では、測定される時間
短縮の度合いはタスクの複雑さやプロセス設計によって一
貫して変動し、文書の下書きが速くなることはタスク構造
の変化をもたらす、必ずしもエンドツーエンドの処理速度
向上と同義ではないことが示されている [2]。これらの観
察結果は、生産性を固定的な「真の値」として扱うのでは
なく、条件に依存する量としてモデル化すべきであるとい
う考え方を後押ししている。

2.2.3 理由付け (rationale)、冗長性、そして 解釈可能な代理指標

LLM はしばしば理由付けや説明を生成するが、これらは
不確実性、リスク、人間による検証の必要性に関する前提
を表面化させる手がかりとして利用できる。しかし、理由

付けの質や冗長さはモデルや設定によって大きく異なり、欠落が体系的に生じる場合もある（例：旧世代モデルでは出力が短くなりがち）。先行研究では、理由付けを因果的な証拠として扱うことには注意が促されている一方で [11]、ロバスト性チェックと組み合わせることで、解釈可能なシグナルとして利用することは支持されている [12]。私たちの代理指標（proxy）アプローチもこの考え方に沿っており、軽量で透明性のある語彙的な代理指標を用い、欠落がある状況でもロバスト性を検証する。

‡ Remark 2.1. settings 補足

これから行う検証では、生成 AI を用いて 2 つの推定値一人間が業務を遂行した場合の所要時間と、AI が業務を行った場合の所要時間を、それぞれ理由付きで見積もらせる。見積もるタスクの分量（単位）に応じて、時間の単位は異なるため、時間削減率（2 つの推定値の比率）で比較を行うことになる。理由を書かせるのは、どこまでの範囲を AI が担うのかにより見積時間が異なってくるので、考え方を記録しておくためである。見積方針の異なるものを混ぜると分析精度が落ちるためできるだけ分解能をあげた分析をするために利用する。

参照する正解値（「真値」）が同じであっても、被験者集団の能力、タスクの範囲や固有の制約など実験ごとに異なるため真値の意味合いは同じではなく、測定には現れない潜在的な誤差を含んでいる。よって、AI の推定値、真値ともに相応の揺れがあることを前提とした分析を行うことになる。

単に回帰分析を行ってモデルの適合度だけを追跡するのではなく、適合度の上昇要因を調べることで見積の揺れの要因となる変数が何であるかを推定するアプローチには十分な意義がある。

評価は推定値の真値からの偏差 ε_i と、乖離率 χ_i で行う。

$$\varepsilon_i = \text{推定値} - \text{真値} \quad (2.1)$$

$$\chi_i = (\text{推定値} - \text{真値}) / \text{真値} \quad (2.2)$$

添え字 $i = 1, 2$ で、それぞれ 1/2 で真値 BM/ref.4 に対する値を表す。本文では、表記の煩雑さを避けるため添え字を省略する。

‡ Remark 2.2. 使用モデル選択根拠と指標

実験が行われた時期の AI 能力と真値の間に相関性があると考えられるので、ref1, ref2 で利用されたモデル GPT3.5, GPT-4o-mini, の他に最近の推論系モデル GPT シリーズを採用する。ref4 では Claude シリーズ (Haiku/Sonnet/Opus) を採用する。最新のモデルを加えているのは、性能が向上した AI なら推定精度も高いと想像されるためである。能力が向上すれば時間見積が正確にできるのかという問題意識もある。

また、回帰分析を行う上で説明変数のバラエティを確保するため、推論能力が低いモデルも分析に加える必要がある。表 24 には、使用したモデル一覧を掲載した。Chatbot Arena <https://openlm.ai/chatbot-arena/> から（アクセス日時：Mar. 4, 2026, JST 19:59）、Elo rating (Arena Elo)、AAII、

MMLU-Pro の 3 つの値が存在するモデルを抽出し、使用したモデルとの対応づけを行っている。モデル名が正確に一致するものがないものはなるべく近似するものを選択している。

3 Problem Setting and Data

3.1 タスク設定

私たちは、11 の職種と 3 種類の共通タスクタイプ T_t をカバーするデータセットを構築し、ナレッジワークにおける時間短縮の推定を研究する。共通タスクタイプ T_t は以下のとおり：

T_1 : 要約（情報の取り込みと統合）

T_2 : 指示文作成（仕様書／ガイドライン／指示文の作成）

T_3 : プレゼン準備（スライド／ストーリーラインの作成）

必要に応じて $t = \{\text{summary, instruction, presentation}\}$ と具体的に表す。各職種は、これらの共通タスクタイプを職務固有の文脈で具体化するが、タスクカテゴリ自体は固定されており、職種間比較が可能になる。

3.2 モデル出力と時間短縮率の推定

各（モデル × 職種）について、以下のモデル推定値を収集する：推定される人間の作業時間 $\hat{t}_{task}^{human}$ （ベースラインの完了時間）推定される AI 支援時の作業時間 $\hat{t}_{task}^{AI}$ （モデルを使用した場合の時間）これら 2 つの推定値から、タスクごとの推定時間短縮率 $\hat{r}_t$ を次のように計算する：

$$\hat{r}_t = 1 - \frac{\hat{t}_{task}^{AI}}{\hat{t}_{task}^{human}} \quad (3.1)$$

私たちは、この短縮率 $\hat{r}_t$ の誤差を 2 種類の参照値に基づいて分析する。1 つは上記 §1 で構成（詳細は付録 C 参照）した職業ベースの観測値（職業真値）、もう 1 つはタスクベースに分解したタスク真値を用いる（Section 4）。また、§3.4 に詳述する分析に基づき、モデルを推定スタイルのセグメント $S = \{A, B, C\}$ に分類する。

A：最新の高性能モデル（GPT-5.2 Instant/Thinking、Claude Opus/Sonnet/Haiku など）

B：レガシーモデル

C：体系的に保守的な推定パターンを示すモデル（例：残存作業を強めに見積もる傾向）

セグメントの定義は、本稿で報告するすべての分析で固定されている。

3.3 重要度ウェイトとタスク／職種の集約

私たちは、タスク重要度 $W_t \in [0, 1]$ と、各タスクが職種全体の業務量にどれだけ寄与するかを示す時間シェアの重み w_t を含めている。これらの重みは次の 2 つの目的に用いられる：

職種レベルの集約値の算出（時間加重平均）

重要度がタスクタイプと交互作用し、推定誤差を説明するかの検証

‡ Remark 3.1. 削減率の偏差と乖離率

職業別タスク別の削減率の偏差と乖離率の代表例を表 25

と表 26 に示す。表 25 は保守的な推定値を出した C のモデル (GPT-5.1 Thinking)、表 26 は楽観的な推定値を出した A のモデル (Haiku4.5) である。タスクごとの時間削減率 $\hat{r}_t$ 、それらの時間比率加重平均

$$\hat{r}_{occ} = \sum_t w_t \hat{r}_t, \quad (3.2)$$

偏差 ε_i と乖離率 χ_i を全職業で一覧にした。

表 27、表 28 は重要度ウェイトを加味したもので、それぞれ同じモデルについて、タスクの重要度を時間削減率に乘じたものを時間比率で加重平均をとったものである。

$$\hat{r}_{occ} = \sum_t w_t W_t \hat{r}_t. \quad (3.3)$$

表 29、表 30 は職種の集約を行ったもので、職業平均をとって集約したものを全モデルで一覧にしたものである。

表 29 は、全職業の平均をとりモデルごとの削減率と誤差を平均値で表したものの。GPT5.1 と GPT5.2 Pro を除いた全てで、ref4 の誤差が小さい。これに対して、表 30 は、削減率に重要度を乗じた場合の職業平均であるが、全てのモデルにおいて BM の誤差が小さい：GPT5.1 と GPT5.2 Pro は、表 29 の ref4 よりも誤差が小さく、他のモデルは全て表 29 の ref4 に匹敵する小ささとなっている。従って、GPT5.1 と GPT5.2 Pro は、他のモデルと何らかの性質が異なっている可能性を暗示する。

3.4 Segment 仮説

まず、モデルの性能指標 X_{elo} (Arena Elo) を説明変数とする誤差の回帰関係を概括する。

$$Y_{mae} = \beta X_{elo} + \alpha, \quad (3.4)$$

簡単のため回帰係数 β と切片 α を省略して略記する場合は記号 $\sim$ を用いる：

$$Y_{mae} \sim X_{elo}. \quad (3.5)$$

目的変数とする誤差は、職業ごとに得られる絶対誤差 $|\varepsilon_{occ}|$ を $n = 11$ 職業で平均した平均誤差 Y_{mae} (mean absolute error) を用いる。

$$Y_{mae} = \frac{1}{n} \sum_{occ} |\varepsilon_{occ}|, \quad \varepsilon_{occ} = \hat{r}_{occ} - r_{occ}^* \quad (3.6)$$

$\hat{r}_{occ}$ は職業ベースの時間削減率 (3.2) or (3.3) である。表 1 には、3 タスクの時間加重平均 (time/imp; time 重みは w_t 、imp 重みは $w_t W_t$) の職業真値 BM/ref4 (B/R) に対する Y_{mae} の回帰係数と相関係数をまとめている。図 1 は代表的な散布図を掲出している。真値種別と重み種別の組合せで $C[B/R, time/imp]$ の様に表記する。

性能指標 X_{elo} が高いほど誤差 Y_{mae} は小さいと期待され、図 1(b) は期待通りになっているが、図 1(a) のように必ずしもそのような傾向は見えてはいない。

- (a) $C[B, time]$ ($Y_{mae} = time_abs_ae_bm$) ではほぼ無相関; Pearson $r = +0.031$ ($p=0.913$) /Spearman $r = -0.159$ ($p=0.571$)
- (b) $C[B, imp]$ ($Y_{mae} = imp_abs_ae2_bm$) では、性能指標 X_{elo} が高いほど誤差が小さい傾向が明瞭; Pearson $r = -0.531$ ($p=0.0418$) /Spearman $r = -0.645$ ($p=0.0095$)

- (c) $C[R, time]$ ($Y_{mae} = time_abs_ae_ref4$) ref4 基準でも、負相関が維持されている (但し、Spearman は有意境界付近 $p=0.0871$) ; Pearson $r = -0.570$ ($p=0.0264$) /Spearman $r = -0.457$ ($p=0.0871$).

散布図 1 を見た印象では、モデルが記述した見積理由の差異 (保守/楽観) を考慮すると、モデルは 3 つの異なるセグメントに分かれているように見える：

- A: 最近の高度推論モデル (GPT5, Opus/Sonnet/Haiku)
- B: 見積の理由記載が薄いレガシーモデル (A,C 以外)
- C: 見積の理由が保守的: gpt52P と gpt51T

モデルの見積誤差には、モデル能力だけでなく「見積スタイル (Estimation Style)」の差が大きく影響し、モデルを一括で回帰すると相殺によって構造が見えにくくなることを示唆している。図 1(a) のように 1 本の回帰で全部まとめると、異なる“見積ポリシー”が平均化されて見えにくくなっており、 $A/B/C$ は「性能差」ではなく、より上位の「推定スタイル (キャリブレーション方針)」の違いに見える」という仮説を導くことができる。

もしそうだとすると、上記の回帰に混ざっているのは: 重要度やタスクによる構造 (観測したい効果)、モデルの“バイアス方針” (保守的・攻め・レガシー)、更に真値 (BM/ref4) の実施条件差が複合的に絡み合い、確かに読みづらくなると考えられる。

(output data) [folder#,subfolder#] filename :

表 1 : [1,1] corr_ArenaElo_vs_errors.csv

図 1(a) : [1,1] elo_vs_mae_time_bm.png

図 1(b) : [1,1] elo_vs_mae_imp_bm.png

図 1(c) : [1,1] elo_vs_mae_imp_ref4.png

3.5 交互作用 (職業真値参照)

図 1(b) では重要度が効いているように見えるが、segment 効果がより効いているという仮説を支持する材料をもう一つ確認しておく。まずベースラインとして、重要度が推定誤差 (過大/過小) に与える影響がタスク種別によって異なるかを検証するため、タスク別の符号付き誤差 ε_t^{occ} (signed error) を目的変数とし、重要度 W_t 、タスク種別 T_t (summary を参照カテゴリ)、および両者の交互作用を説明変数とする回帰 (OLS、HC3 ロバスト標準誤差) を推定する。

$$\varepsilon_t^{occ} \sim W_t * T_t. \quad (3.7)$$

タスク種別が説明変数に参加するため、目的変数の誤差もタスク種別ごとに与える必要があるが、ここでは簡単に職業真値からの偏差で符号付き誤差を定義する。タスク真値への分解は後述する：

$$\varepsilon_t^{occ} = \hat{r}_t^{occ} - r_{occ}^*. \quad (3.8)$$

交互作用はシンボリックに

$$A * B = A + B + A : B \quad (3.9)$$

と表すが、具体的には A, B の各成分 a, b で展開して

$$A * B = \sum_a \beta_a I(a) + \sum_b \beta_b I(b) + \sum_{a:b} \beta_{a:b} I(a) I(b) \quad (3.10)$$




図 1: Correlations between Arena Elo and MAE.

表 1: Arena Elo と誤差指標の相関

weight	truth type	Pearson r	Pearson p	Spearman r	Spearman p	slope β	slope p
time	BM	0.031	0.913	-0.159	0.5705	1.29867	0.9126
imp	BM	-0.531	0.0418	-0.645	0.0095	-0.00013	0.0418
time	ref4	-0.570	0.0264	-0.457	0.0871	-0.00022	0.0264
imp	ref4	-0.403	0.1366	-0.294	0.2881	-0.00016	0.1366

を意味する。 $a : b$ は a と b の交差項を表す。 a が名義変数 A の項目値であることを明示する場合には $A.a$ と表現する。 $I(a)$ は名義変数の場合 1、それ以外は A の実現値をとる。

回帰係数は付録 A.1.3 付録表 8 に示される通りで、この場合、重要度とタスクの交互作用は p 値を見る限り BM/ref4 とも有意ではないという結果だが、ref4 基準の“summary (参照タスク) の重要度効果 (importance 主効果)”は有意という結果を得た。また、回帰係数の符号を見る限り重要度が上がるほど誤差がプラス方向に動く (過大推定に寄る) 傾向が読み取れる。ref4 基準では更にこの傾向が強く、特に instruction で最も強い。これは、重要度という“実装・採用されやすさ・運用の手厚さ”の代理変数が、タスクによって誤差の出方を変えるということであり、同じ重要度でも、要約と指示書で挙動が違うことを示唆する。

(output data 回帰係数ファイル) :

[1,1] regression_coef_importance_task_BM_ref4.csv

[1,1] regression_slopes_by_task_BM_ref4.csv

ここで、推定誤差に対する重要度効果がモデルの“見積スタイル”の違いにより混在している可能性を検証するため、セグメント項 $S = \{s|A,B,C\}$ を (3.7) に明示的に加えて推定してみると (分析 2)、重要度 W_t の効果は弱いことがわかる (重要度タスク交互作用・付録 A.1.3):

$$\varepsilon_t^{occ} \sim W_t * T_t + S. \quad (3.11)$$

職業真値 ($r_{occ}^* = r_{occ}^{BM}$) に基づく様々なセグメント回帰を付録 A.1 に示すが、セグメント差を明示的に考慮することが誤差構造の説明に有効であることも示唆される (表 10)。 (付録 A.1.2)

ベースライン回帰 (付録 A.1.2)

$$\varepsilon_t^{occ} \sim T_t + S, \quad (3.12)$$

三重交互作用 (付録 A.1.5)

$$\varepsilon_t^{occ} \sim W_t * T_t * S. \quad (3.13)$$

セグメントの効果は、推定根拠の違いの代理変数としてプロキシ特徴量 ($P_{tot}, P_{sum}, P_{ins}, P_{pre}$) 付録 B から説明できることが期待される。ベースライン (3.12) にプロキシ変数 P_{tot} を追加したもの (付録 A.1.4)

$$\varepsilon_t^{occ} \sim T_t + S + P_{tot}, \quad (3.14)$$

或いは、プロキシとセグメントの交互作用を考えることもできる (付録 B.3)。

$$\varepsilon_t^{occ} \sim P_{tot} * S. \quad (3.15)$$

4 参照値と誤差の定義

4.1 条件付き量としての参照値

生産性評価における中心的な課題は、「真の時間短縮量 (ground truth time-savings)」が普遍的な定数ではないという点にある。実際に得られる時間短縮は、レビューの厳密さ、例外処理の頻度、ステークホルダー間の整合性、ツール環境、リスク許容度といったワークフロー条件に依存する。そのため、私たちは参照値を絶対的な真値ではなく、条件付きの参照推定値として扱う。本研究では、次の 2 種類の参照ソースを用いる：

B: BM (ベンチマーク実験参照値)：特定の評価手順のもとで、職種レベルの時間短縮を実験的に導出した参照値。

R: ref4 (ログ由来の参照値)：別の手順と前提に基づき、インタラクションログから推定された参照値。

本論文の主要な分析では、BM を用いてタスク真値の分解 (Section 5) および タスクレベルの誤差評価を行う。ref4 は主セグメント傾向や参照値の意味論に関する議論に使用する。

4.2 職種参照値 (occupation-truth) に基づく誤差

タスクレベルの参照値が利用できない場合によく用いられる方法として、各タスクの推定値を職種レベルの参照値と比較するという手法がある。私たちは、BM (ベンチマーク) を基準とした職種参照値ベースのタスク誤差を次のように定義する ((3.8) で $* = BM$ にとる)：

$$\varepsilon_t^{occ} = \hat{r}_t^{occ} - r_{occ}^{BM}. \quad (4.1)$$

ここで r_{occ}^{BM} は職種 occ の BM 参照時間短縮率である。この定義はシンプルだが、タスクと職種の意味論が混ざってしまう可能性がある。つまり、タスクレベルの予測を職種レベルの参照値と比較するため、混合的なアーティファクトが生じる可能性がある。本論文では、ロバスト性に関する主張を補強し、タスク真値ベースの評価との対比を示すために、職種参照値ベースの回帰分析を付録 A に掲載している。

4.3 タスク参照値に基づく誤差 (主要指標)

より解釈しやすいタスクレベルの評価を得るため、タスク参照値 (task-truth) に基づく誤差を次のように定義する：

$$\varepsilon_t^* = \hat{r}_t^{occ} - r_t^*. \quad (4.2)$$

ここで r_t^* は、Section 5 のタスク真値分解 (task-truth decomposition) によって推定されるタスク固有の参照値である。 ε_t^* の正負によって、次のように推定傾向を読み取る：

$\varepsilon_t^* < 0$ ：保守的な推定 (タスク真値よりも低い時間短縮を予測)

$\varepsilon_t^* > 0$ ：過大推定 (タスク真値よりも高い時間短縮を予測)

5 タスク真値 (Task-Truth) 分解

5.1 動機 (Motivation)

職種レベルの参照値は、業務実験やログから得られる場合がある一方で、タスクレベルの参照値は、特定の限られた職種や業務において測定されることはほとんどない。そのため、 $\hat{r}_t^{occ}$ (タスクごとの推定時間短縮率) を職種レベルの参照値 r_{occ}^{BM} と比較すると、タスクと職種の寄与が混ざり合う (mixing artifacts) 可能性がある。より解釈しやすいタスクレベルの評価を可能にするため、私たちは線形混合の仮定のもとで、職種レベルの参照値からタスク固有の参照値 r_t^* を推定する。特に、タスクの構成比が職種ごとに異なる場合に問題が顕著になる。この課題に対処するため、私たちは最小限の線形モデルを用いて、職種レベルの参照値 r_{occ}^{BM} からタスクレベルの参照値 r_t^* を推定する。

5.2 線形混合モデル (Linear Mixing Model)

タスクタイプ ($t \in \text{summary, instruction, presentation}$) に対する、その職種の時間シェア重みを w_{occ}^t とする。ここで次の関係を仮定する：

$$r_{occ}^{BM} \approx \sum_t w_{occ}^t r_t^*. \quad (5.1)$$

つまり、職種レベルの時間短縮率は、タスクごとの真値 r_t^* の重み付き平均で近似できるとする。本研究のデータセットには 11 の職種があり、未知のタスク真値 r_t^* は 3 つであるため、最小二乗法によって r_t^* を推定する。

私たちは、

(a). 制約なしの解 (unconstrained solution)

(b). 値を $[0,1]$ にクリップした解 (clipped solution)

の両方を報告する [file1]。下流の分析では、無効な時間短縮率 (0 未満や 1 超) を避けるため、クリップした解を使用する。 $C[B, time]$ の仕様に基づく推定では、クリップ後のタスク真値 (task-truth) は次のとおりである：

$$r_1^* = 0.8408 \quad (\text{for summary}) \quad (5.2)$$

$$r_2^* = 0.5127 \quad (\text{for instruction}) \quad (5.3)$$

$$r_3^* = 0.4983 \quad (\text{for presentation}). \quad (5.4)$$

5.3 分解の品質と限界

この分解はあくまで近似であるため、再構成された職種レベルの値 $\hat{r}_{occ}^{BM}$ と実際の r_{occ}^{BM} を比較し、再構成精度 (MAE / R^2) を評価する。これらの診断結果は付録 A.2.2 に報告している [file2,3]。これにより、タスク真値が「観測された真値」ではなく、推定された参照値 (inferred reference) であることが明確になる。それでも、職種参照値との比較よりも、より妥当性の高いタスクレベルの誤差定義を提供できる点で有用である。

(output data)

file1:[3,1] task_truth_decomposition.csv

file2:[3,1] task_truth_reconstruction_detail.csv

file3:[3,1] task_truth_reconstruction_metrics.csv

6 Results

6.1 R1. タスク真値ベースでも、見積スタイル (A/B/C) の差が支配的である

$C[B, time]$ 仕様のタスク真値に基づくタスク別誤差を ε_t^* と定義し、まずセグメント (A/B/C) による誤差の系統差を評価した。

$$\varepsilon_t^* \sim S + T_t, \quad (6.1)$$

この回帰では、B 群と C 群はいずれも参照基準の A 群に比べて誤差が有意に小さく (負方向)、より保守的な見積を行う傾向が確認された (係数： $S.B < 0$, $S.C < 0$ 、いずれも有意)。(表 2 参照)。このセグメント差 (A に比べ B/C が保守的) は、職業真値ベースの解析でも同方向に観察され (付録 A.1.2: 表 5 参照)、タスク真値ベースに置き換えても有意に残る。見積の誤差構造がモデル能力だけでなく、ス

表 2: タスク真値回帰: $\varepsilon_t^* \sim S + T_t$

term	coefficient	p
intercept	0.2818	0
<i>S.B</i>	-0.1319	0
<i>S.C</i>	-0.2297	0
<i>T.pres</i>	-0.0162	0.2595
<i>T.sum</i>	-0.2629	0

タイル（安全側の見積方針）に強く依存することを示す。分布図 2 およびタスク別分布図 3 は、セグメント間で誤差分布の位置が体系的にずれることを視覚的に示している。同時に、タスク種別の差も確認された。instruction（指示書）を参照とした場合、summary（要約）では誤差が大きく負に偏りやすく、推定削減率がタスク真値より低めに出る傾向が見られた。一方、presentation（資料）は instruction と有意な差が小さい（表 2）。このタスク差は、後述の重要度効果の解釈において「どのタスクで誤差が系統的に出やすいか」を示す基礎情報となる。




図 2: Task-truth-based error by segment ($C[B, time]$)




図 3: Error by segment and task ($C[B, time]$)

(output data)

Table 2: [4,1] TASKTRUTH_reg_segment_task.csv

Figures 2, 3: [3,2] out_Figure_2_3

6.2 R2. 理由文 proxy は保守性と整合し、タスク・セグメントを制御しても残る

次に、モデルが提示する理由文から「残作業（レビュー/調整/検証等）residual」「スコープ拡張（初版→運用など）scope」「慎重姿勢（前提・不確実性・人手残存等）caution」

をキーワードに基づき定量化し (P_{re}, P_{sc}, P_{ca})、これらの平均値 P_{tot} を proxy 変数としてモデル別に付与した。主回帰

$$\varepsilon_t^* \sim P_{tot} + T_t + S \quad (6.2)$$

表 3 において、segment B と segment C の両方が基準の segment A に対して有意に負であり、A 群より保守的な推定スタイルを示した。また、 P_{tot} も有意に負であり、理由文に残作業・慎重姿勢・スコープ拡張が多く含まれるほど、推定はより保守的になる（過大推定が抑制される）傾向が確認された。したがって、保守性は segment 差だけでも proxy だけでなく、その両方で説明される。重要な点は、タスク差およびセグメント差を制御した上でも P_{tot} の効果が残ることである。すなわち、単に「A/B/C のどの群に属するか」だけでなく、理由文に表出する残作業・慎重姿勢の強さが、見積の保守性と整合している。

ただし、B 群（レガシーモデル）では理由文が短く P_{tot} が欠損しやすい。欠損が結論を歪めないことを確認するため、(i) complete-case、(ii) 欠損=0 + 欠損ダミー、(iii) 欠損=セグメント平均 + 欠損ダミーの 3 仕様で感度分析を行った（Appendix B.2）。仕様間で proxy 効果の符号が大きく反転しないこと、欠損ダミーは「説明スタイル（言語量）」を表す別要因として解釈すべきであることを示し、proxy 結果の頑健性を補強した（付録表 17）。

表 3: タスク真値回帰: $\varepsilon_t^* \sim P_{tot} + T_t + S$.

term	coefficient	p
intercept	0.4702	0
P_{tot}	-0.0277	0
<i>S.B</i>	-0.2495	0
<i>S.C</i>	-0.1517	0
<i>T.pres</i>	-0.0162	0.2458
<i>T.sum</i>	-0.2629	0

(output data) :

表 3: [4,1] TASKTRUTH_reg_proxy_task_segment.csv

付録表 17: [4,2] proxy_sensitivity_comparison.csv

6.3 R3. 重要度タスク交互作用は、タスク真値ベースでは強くは出ない

最後に、重要度 W_t とタスク種別 T の交互作用が誤差を系統的に説明するかを検証した。

$$\varepsilon_t^* \sim W_t * T_t + S \quad (6.3)$$

表 4 では、重要度 W_t の主効果および重要度・タスクの交互作用 $W_t : T_t$ は統計的に強くは示されなかった。したがって、重要度による誤差抑制/増幅を一般化して主張するのは慎重であるべきである。（この回帰でもセグメント差自体は強く、B: -0.1504、C: -0.2297 と有意に負となっている。）

この結果は、職業真値ベース（タスク推定 - 職業参照値）の枠組みで観察されやすい重要度パターンが、タスク真値が未観測であることによる混合の影響（タスクの線形混合

を職業真値として扱うこと）に起因していた可能性を示唆する。重要度は依然として「参照値が反映する運用条件」の proxy として議論価値があるが、本データにおいては、主要因としてはセグメント差と理由文 proxy がより説明力を持つ。

表 4: タスク真値回帰: $\varepsilon_t^* \sim W_t * T_t + S$.

term	coefficient	p
intercept	0.3116	0
$S.B$	-0.1504	0
$S.C$	-0.2297	0
$T.sum$	-0.2664	0
$T.pres$	-0.0035	0.9386
W_t	-0.0352	0.4301
$W_t:T.sum$	0.0007	0.9891
$W_t:T.pres$	-0.0225	0.7019

表 4 (output data):

[4,1] TASKTRUTH_reg_importance_task_segment.csv

7 Discussion

本研究は、LLM の生産性見積に関して、一般的な能力指標とは異なる観点が重要であることを示した。第一に、モデルは見積誤差の「平均位置」を規定する推定スタイル (A/B/C) に分かれ、これが誤差の大部分を説明し得る。実務的には、モデル選定において「高性能モデルほど常に正確」という期待よりも、「どの程度保守的に見積もるか」「残作業をどの範囲まで含めるか」といった見積方針を、モデル比較の軸として明示的に扱う必要がある。

第二に、理由文から抽出した proxy が保守性と整合するという結果は、削減率見積が単なる当て推量ではなく、少なくとも一部が「残作業・スコープ・慎重姿勢」という説明可能な要因に支えられている可能性を示す。これは、モデルが提示する説明をそのまま信頼するというより、説明を定量化して「どのモデルがどの条件を想定して見積もっているか」を比較する評価枠組みにつながる。特に、B 群で proxy が欠損しやすいという事実は、モデル能力差というより説明スタイル (言語量) の差として扱うべきであり、欠損を明示した感度分析が重要である。

第三に、タスク真値分解により、タスク真値が直接観測できない状況でもタスクレベル誤差を評価できるようになり、重要度×タスクのような交互作用の過主張を避けられる。分解は近似であり、再構成誤差がゼロになるわけではないが、少なくとも「職業真値をタスク真値と同一視する」よりは整合的な議論が可能になる。今後は、実運用の条件 (レビュー強度、再作業率、データ制約など) を参照値側にも明示的に付与することで、参照値の“性格”をより厳密に定義し、モデルの推定スタイルとの対応を検証できるだろう。

総じて、LLM の生産性評価におけるボトルネックは「モデルの賢さ」そのものよりも、「参照値が何を表している

か」と「モデルがどの条件を想定して見積もっているか」を区別できていない点にある。本研究の枠組み (セグメント化、理由 proxy、タスク真値分解、欠損感度分析) は、企業導入におけるモデル選定・評価設計の透明性を高めるための実践的な手がかりを提供する。

8 制限事項: Limitations

1. 参照値と条件依存性

BM に基づく参照値は、特定の実験条件と運用上の前提に依存している。実際の業務における時間短縮は、ワークフロー設計、レビューの厳密さ、例外処理の頻度、リスク許容度といった要因に左右される。そのため、本研究の結論は「普遍的な時間短縮の真実」ではなく、評価対象とした参照設定の性質として解釈されるべきである。

2. タスク真値の分解は近似である

タスク真値 (task truth) は、職種レベルの参照値から線形混合の仮定と最小二乗推定 (値域を [0,1] にクリッピング) を用いて推定している。これはタスクと職種の比較より解釈性を高めるが、あくまで推定された参照値である。分解の適合度指標 (MAE / R^2) を報告するのは、タスク真値が観測された“真の値”ではないことを明確にするためである。

3. プロキシ構築は粗く、言語依存的である

理由付け (rationale) から構築したプロキシは、テキスト長で正規化したキーワード数に依存している。この方法は意図的に軽量で透明性が高いが、意味的に同等の表現を見逃したり、言い回しに敏感であったり、冗長さ (verbosity) と内容を混同する可能性がある。より堅牢な NLP 特徴 (例: 残存作業概念への埋め込み類似度など) は測定精度を高めうるが、本研究の範囲外である。

4. proxy の欠損はランダムではない

レガシーモデルは短い rationale を生成しがちであり、その結果として proxy の欠損が体系的に発生する。これに対処するため、完全ケース分析や代入+欠損インジケータを用いた感度分析を行っているが、因果的な解釈には限界がある。欠損インジケータは、別のスタイル/冗長性要因を捉えるものとして独立に解釈すべきである。

5. モデル集合と外的妥当性

評価したモデル集合は、本研究時点で利用可能だったモデルと設定を反映している。A/B/C のセグメント分けは、観察された推定スタイルに基づく実務的な分類であり、本研究のデータでは安定しているものの、プロンプト方針、ツール利用、組織的文脈が変われば境界が変動する可能性がある。

6. 因果的主張は行わない

本研究の分析は関連性 (associative) に基づくものである。プロキシ言語が慎重さを引き起こすと主張するものではなく、選択した参照設定において、理由付けのシグナルが推定行動と整合的であることを示す

にとどまる。

9 Conclusion

本研究は、ビジネスワークフローにおける LLM ベースの時間短縮予測の信頼性を検証し、推定誤差を体系的に形成する要因を明らかにした。11 の職種と 3 種類の共通タスクを用いて、職種レベルの BM 参照値 $C[B, time]$ から推定したタスク真値 (task truths: 要約 0.8408、指示文作成 0.5127、プレゼン準備 0.4983) に基づき、タスクレベルの推定値を評価した。得られた結論は以下の 3 点である。

第一に、モデルは安定した「推定スタイル」を示し、それが体系的なバイアスの方向を決定づける。Segment A と比較して、Segments B および C は明確により保守的な推定を行い、この差異はタスク真値評価においても一貫して観察された。

第二に、モデルの rationale から構築した軽量で解釈可能なプロキシ (残存作業、スコープ拡張、慎重さを捉える指標) は、タスクタイプやセグメントを統制した後でも保守性と整合的であり、欠損に対する感度分析によってその頑健性が確認された。

第三に、重要度 (importance) に基づく調整効果はタスク真値評価では弱く、職種レベル比較で観察された一部の重要度パターンは、真のタスクレベルのメカニズムではなく、参照値の混合による可能性が示唆された。

これらの実証的知見に加えて、本研究は企業における評価のより広い含意を示している。すなわち、生産性に関する「真値」は条件依存的で定義に左右されるため、信頼できる評価には、参照値の意味、キャリブレーションスタイル、ワークフローに残る作業の扱いを明示的に管理することが不可欠であり、単なるモデル性能だけでは不十分である。本研究で提案した、セグメンテーション、rationale 由来のプロキシ、タスク真値分解、欠損感度分析の組み合わせは、生産性が重要となる実務環境において LLM を選定・検証するための実践的な枠組みを提供する。

付録 A 職種参照値 (Occupation-Truth) とタスク参照値 (Task-Truth) の比較

この付録では、(i) 職種参照値 (occupation-truth) を基準に、タスクレベルの予測を評価する回帰分析、(ii) 本文で使ったタスク真値 (task-truth) 分解の詳細を示す。

これらの資料は次の 2 つの目的を持つ: (a) 主要な結論 (例: セグメントごとの推定スタイルの違い) が、どちらの評価方法でも確認できることを検証するため。(b) 職種参照値ベースからタスク参照値ベースへ評価方法を切り替えた際に、どこで結論が異なるのか (例: タスク重要度の効果) を明確にするため。

A.1 職種真値 (occupation-truth) に基づくベースライン回帰

A.1.1 誤差の定義 (occupation-truth)

職種真値 (特に断りがない限り BM) を基準とするベースラインでは、タスクレベルの誤差を次のように定義する:

$$\varepsilon_t^{occ} = \hat{r}_t^{occ} - r_{occ}^{BM}. \quad (\text{付録 A.1})$$

ここで $\hat{r}_t^{occ}$ はモデルが推定したタスクタイプごとの時間短縮率、 r_{occ}^{BM} は対応する職種に対する BM 参照値である。このベースラインは、タスクレベルの真値が利用できない場合によく用いられる手法である。しかし、タスクレベルの予測を職種レベルの参照値と比較するため、職種ごとにタスク構成比が異なる場合には “mixing artifacts” (混合による歪み) が生じる可能性がある。

A.1.2 セグメントおよびタスクの統制

私たちは次のベースライン回帰モデルを推定する:

$$\varepsilon_t^{occ} \sim S + T_t. \quad (\text{付録 A.2})$$

推定には OLS (通常最小二乗法) を使い、標準誤差には HC3 ロバスト標準誤差を採用する。対応する係数表は付録表 5 に掲載している。この表は、本文の主要なタスク真値 (task-truth) 回帰 (図 2、図 3 およびセグメント回帰表 2) と直接比較できる。本研究のデータでは、セグメント間の推定スタイルの方向性 (セグメント B/C がセグメント A より保守的) が、occupation-truth と task-truth のどちらの評価方法でも一貫して観察される。

表 5: baseline 回帰: $\varepsilon_t^{occ} \sim S + T_t$

term	coefficient	p
intercept	0.1944	0
$S.B$	-0.1319	0
$S.C$	-0.2297	0
$T.pres$	-0.0305	0.0686
$T.sum$	0.0652	0

表 5 (output data):

[5,1] APPX_OCCBM_reg_segment_task.csv

A.1.3 重要度とタスクの交互作用 (occupation-truth)

次の回帰モデルも推定する:

$$\varepsilon_t^{occ} \sim W_t * T_t + S. \quad (\text{付録 A.3})$$

この結果は付録表 6 に掲載している。このベースライン分析は、本文で示した「タスク真値 (task-truth) 評価では重要度の効果が弱い」という結果を位置づけるために用いている。比較を明確にするため、付録表 7 では、task-truth と occupation-truth (BM) における重要度の回帰係数を並べて提示している。

segment 項がない場合 (3.7) の回帰 $\varepsilon_t^{occ} \sim W_t * T_t$ の結果は表 8 である。

表 6 (output data):

表 6: baseline 回帰: $\varepsilon_t^{occ} \sim W_t * T_t + S$

term	coefficient	p
intercept	0.2908	0
<i>S.B</i>	-0.1941	0
<i>S.C</i>	-0.2297	0
<i>T.sum</i>	-0.101	0.0206
<i>T.pres</i>	-0.0304	0.5443
<i>W_t</i>	-0.1128	0.0436
<i>W_t:T.sum</i>	-0.084	0.1842
<i>W_t:T.pres</i>	-0.0053	0.9388

表 7: task-truth vs occ-truth: $\varepsilon_t^{occ} \sim W_t * T_t + S$

term	coef_occ	p_occ	coef_task	p_task
<i>W_t</i>	-0.1128	0.0436	-0.0352	0.4301
<i>W_t:T.sum</i>	-0.084	0.1842	0.0007	0.9891
<i>W_t:T.pres</i>	-0.0053	0.9388	-0.0225	0.7019

表 8: importance-task 交互作用

baseline	term	slope	p	se(HC3)
BM	sum	0.0199	0.6918	0.0503
BM	inst	0.1115	0.2037	0.0721
BM	pres	0.0918	0.3427	0.0757
ref4	sum	0.1795	0.0003	0.0497
ref4	inst	0.2786	0.1788	0.0737
ref4	pres	0.0372	0.0821	0.0819

[5,1] APPX_OCCBM_reg_importance_task_segment.csv
表 7 (output data):

[5,2] task_vs_occ_importance_comparison.csv
表 8 (output data)

[1,1] regression_coef_importance_task_BM_ref4.csv
[1,1] regression_slopes_by_task_BM_ref4.csv

A.1.4 プロキシ回帰 (occupation-truth)

最後に、occupation-truth の誤差定義に基づいて、次のプロキシ回帰を推定する：

$$\varepsilon_t^{occ} \sim P_{tot} + T_t + S. \quad (\text{付録 A.4})$$

proxy 変数は一部のモデルで欠損しているため、ここでは完全ケース版 (complete-case) の結果を報告し、関連する感度分析は付録 付録 B に示している。occupation-truth に基づくプロキシ回帰の結果は付録表 9 に掲載しており、本文の主要な proxy 回帰 (表 3) と比較できるよう、occupation-truth ベースの対応回帰も付録に示す。occupation-truth と task-truth の proxy 回帰結果の差は、(i) 各タスク推定を職業レベル参照値と比較するか、タスクレベル参照値と比較するかという誤差定義の違い、および (ii) 目的変数や結合後データの欠損により回帰に含まれる有効観測が異なること、の双方から生じうる。

表 9 (output data):

[5,1] APPX_OCCBM_reg_proxy_task_segment.csv

表 9: proxy 回帰: $\varepsilon_t^{occ} \sim P_{tot} + T_t + S$

term	coefficient	p
intercept	0.3823	0
<i>P_{tot}</i>	-0.0277	0
<i>S.C</i>	-0.1517	0
<i>S.B</i>	-0.2495	0
<i>T.pres</i>	-0.0305	0.0631
<i>T.sum</i>	0.0652	0

A.1.5 (交互 2) 三重交互作用

更に、(3.11) を base モデルとして、full モデル

$$\varepsilon_{task}^{occ} \sim W_t * T_t * S, \quad (\text{付録 A.5})$$

を推定し、いずれも HC3 ロバスト標準誤差を用いた。結果として、full モデルは base モデルより適合度が改善し (BM: $R^2=0.303 \rightarrow 0.340$, AIC=-486.19 $\rightarrow$ -493.74; ref4: $R^2=0.242 \rightarrow 0.299$, AIC=-312.64 $\rightarrow$ -331.69)、セグメント差を明示的に考慮することが誤差構造の説明に有効であった (表 10)。表 10 (output data): [1,2] segmented_regression_fit.csv

表 10: セグメント導入効果: R^2 /AIC

baseline	spec	R^2	AIC
BM	base	0.30273	-486.187
BM	full	0.34048	-493.742
ref4	base	0.24188	-312.643
ref4	full	0.29939	-331.693

セグメントの平均バイアス (切片差) について、base モデルでは A を基準として B および C が有意に低い誤差 (より過小推定側) にシフトしていた。具体的に BM 基準では B が -0.194 ($p < 10^{-16}$)、C が -0.230 ($p < 10^{-42}$) であり、ref4 基準でも B が -0.077 ($p = 0.009$)、C が -0.230 ($p < 10^{-29}$) であった。これは、推定誤差の大部分が「重要度やタスク以前に、モデル群ごとの一貫した見積バイアス (保守/非保守)」によって説明され得ることを示唆する (表 11)。表 11 (output data): [1,2] segmented_regression_key_terms.csv

表 11: 回帰係数 segment bias

baseline	spec	term	coef.	se(HC3)	p
BM	base	<i>S.B</i>	-0.1941	0.0229	2.6E-17
BM	base	<i>S.C</i>	-0.2297	0.0166	2.2E-43
ref4	base	<i>S.B</i>	-0.0774	0.0296	0.0091
ref4	base	<i>S.C</i>	-0.2297	0.0201	2.6E-30

一方、instruction タスクにおける重要度反応のセグメント差 ($W_t * T_{ins} * S$) については (表 12)、full モデルで正の係数が推定されたものの、統計的には有意に至らなかった (BM: B で +0.358, $p=0.166$; C で +0.181, $p=0.540$ 。ref4: B で +0.393, $p=0.223$; C で +0.181, $p=0.518$)。し

たがって本データでは、instructionでの重要度効果の異質性は「セグメント間で明確に異なる」と断定するよりも、まずはセグメントごとの切片差（平均バイアス）の寄与が大きいと結論づけるのが妥当である。表 12 (output data): [1,2] segmented_regression_key_terms.csv

表 12: 回帰係数 $W_t * T.ins * S$

baseline	spec	term	coef.	se(HC3)	p
BM	full	$W_t:T.ins:S.B$	0.3577	0.2584	0.1663
BM	full	$W_t:T.ins:S.C$	0.1809	0.2955	0.5404
ref4	full	$W_t:T.ins:S.B$	0.3929	0.3222	0.2226
ref4	full	$W_t:T.ins:S.C$	0.1809	0.2796	0.5176

A.2 タスク真値 (task-truth) 分解の詳細

A.2.1 分解結果

すべての職種（本研究では 11 職種）を対象に、(5.1) に基づいて最小二乗法によって r_t^* を推定する。

表 13: 推定タスク真値 (bare)

baseline	weight	r_1^*	r_2^*	r_3^*
BM	time	0.8408	0.5127	0.4983
BM	imp	0.7499	0.5424	0.5483
ref4	time	0.8406	0.4309	1.1099
ref4	imp	0.8396	0.5250	1.0189

時間短縮率は本来 $[0, 1]$ に収まるべきであるため、推定値 $\hat{r}_t^*$ を $[0, 1]$ にクリップし、下流の分析ではクリップ後の値を使用する。

表 14: 推定タスク真値 (clipped)

baseline	weight	r_1^*	r_2^*	r_3^*
BM	time	0.8408	0.5127	0.4983
BM	imp	0.7499	0.5424	0.5483
ref4	time	0.8406	0.4309	1
ref4	imp	0.8396	0.5250	1

$C[B, time]$ 設定における推定タスク真値（クリップ後）が得られる。

$$r_{sum}^* = 0.8408 \quad (\text{summary}) \quad (\text{付録 A.6})$$

$$r_{ins}^* = 0.5127 \quad (\text{instruction}) \quad (\text{付録 A.7})$$

$$r_{pre}^* = 0.4983 \quad (\text{presentation}) \quad (\text{付録 A.8})$$

A.2.2 タスク分解の適合性と再構成誤差

分解モデルが職種レベルの参照値をどの程度うまく説明しているかを定量化するため、次のように再構成値を計算する：

$$\hat{r}_{occ}^{BM} = \sum_t w_{occ}^t \hat{r}_t^* \quad (\text{付録 A.9})$$

そして、この再構成値と実際の職種レベル参照値 r_{occ}^{BM} を比較し、再構成誤差 (MAE / RMSE / R^2) を報告する（付

録図 4、指標表 15、誤差表 16 を参照）。これらの診断結果は、タスク真値が「観測された真の値」ではなく、推定された参照値 (inferred reference) であることを明確に示す。それでも、タスク予測を職種レベル参照値と比較するよりも、より妥当性の高いタスクレベルの誤差定義を提供する点で有用である。




図 4: Task-truth decomposition fit

表 15: 再構成誤差 MAE / RMSE / R^2 (clipped)

baseline	weight	MAE	RMSE	R^2
BM	time	0.0584	0.0700	0.3047
BM	imp	0.0617	0.0746	0.2101
ref4	time	0.0914	0.1084	0.2584
ref4	imp	0.0791	0.1013	0.3520

表 16: $C[B, time]$ の職業真値の再現誤差 $r_{occ}^{BM}, \hat{r}_{occ}^{BM}$

occ_id	occ_name	true value	reconst.	abs_error
1	経営コンサル	0.5423	0.5726	0.0302
2	事業企画	0.5198	0.5547	0.0349
2.2	マーケティング	0.5473	0.5868	0.0395
3	PM/PdM	0.5467	0.5412	0.0055
4	ライター	0.612	0.7067	0.0947
5	営業助手	0.5735	0.6083	0.0348
6	研修講師	0.665	0.5697	0.0953
7	財務経理	0.8	0.6575	0.1425
7.2	財務経理 2	0.6164	0.5764	0.0400
8	CS	0.68	0.6418	0.0382
8.2	CS2	0.4984	0.5850	0.0866

(output data) :

図 4: [3,3] Figure_task_truth_decomposition_R2fit.png

タスク真値分解 [3,1] task_truth_decomposition.csv

表 15 [3,1] task_truth_reconstruction_metrics.csv

表 16 [3,1] task_truth_reconstruction_detail.csv

付録 B プロキシ構築と感度分析

この付録では、理由付け (rationale) から導出したプロキシ特徴量と、体系的な欠損 (systematic missingness) に対処するための感度分析について説明する。

B.1 キーワード辞書と正規化

B.1.1 プロキシの定義

私たちは、理由付け (rationale) テキストから3つの解釈可能な構成要素を用いて、モデルレベルのプロキシスコア $P_T = \{P_{re}, P_{sc}, P_{ca}\}$ を定義する。各モデルについて、抽出した rationale テキスト内のキーワード出現数をカウントし、テキスト長で正規化 (1,000 文字あたりの出現数) を行って P_T とする。これらを規定するキーワードの構成は:

1. 残存作業 (Residual work) P_{re} : 検証、レビュー、承認、調整、例外処理、コンプライアンス関連の作業を示すキーワード。
2. スコープ拡張 (Scope broadening) P_{sc} : 見積もりがエンドツーエンドのワークフロー範囲を含んでいることを示すキーワード (例: 「first draft」vs 「deployment / operations」)。
3. 慎重さ・不確実性 (Caution / uncertainty) P_{ca} : 不確実性、前提、リスク、残存する人間作業への明示的言及を示すキーワード。

具体的なキーワードリストと正規化手順は、公開しているパイプラインコード (付録 [付録 D](#)) に含まれている。 P_{tot} は、これら3つの構成要素スコアの平均として計算される。

B.1.2 解釈と注意点 (Interpretation and caveats)

このプロキシは、意図的に軽量で透明性の高い設計になっている。そのため、すべての意味的なバリエーションを捉えるわけではなく、文章量 (verbosity) と相関する可能性もある。付録 [B.3](#) に見るように、現時点では proxy 単独での説明力は殆どない。

したがって、 P_{tot} はモデルが明示的に述べている前提や慎重さを示す“解釈可能なシグナル”として扱い、因果的な証拠 (causal evidence) としては扱わない。

B.2 欠損に対する感度分析 (Missingness sensitivity analyses)

P_T は、理由付け (rationale) が短いレガシーモデルほど欠損しやすいという体系的な傾向がある。このため、プロキシに関する結論が「欠損処理の方法によるアーティファクト」にならないよう、次の3つの仕様で分析を行う: (i) Complete-case (完全ケース): 全ての P_T が利用可能なモデルのみで推定。

(ii) Zero-imputation + missing indicator (ゼロ代入+欠損インジケータ): 欠損した P_T を0で置き換え、さらに欠損を示すバイナリ変数を追加。

(iii) Segment-mean imputation + missing indicator (セグ

メント平均代入+欠損インジケータ): 欠損した P_T を同一セグメントの平均値で置き換え、欠損インジケータも追加。

係数とp値は付録表 [17](#) に報告している。これらの仕様を比較した結果、proxy の効果は符号反転を起こさない一方で、欠損インジケータは別の要因 (例: 文章量やスタイルの違い) を捉えており、 P_{tot} とは独立に解釈すべきである。

即ち、「理由文に残作業・慎重姿勢・スコープ拡張のシグナルが多いほど、推定はより保守的になる」という結論が、欠損処理のやり方に依存していないことを意味する。次に、missing indicator (proxy_miss) がどちらの仕様でも有意でないのも重要である。0.044 ($p=0.4077$)、0.0463 ($p=0.3766$) なので、「proxy が取れない/0になるケースそのもの」が誤差を説明しているとは言えない。言い換えると、proxy 効果は「欠損の副作用」ではなく、proxy の中身自体に対応している可能性が高い。

表 17: proxy 欠損の感度分析

spec	Complete only	All models: proxy0+miss.	All models: seg.mean+miss.
proxy_term	proxy_total	proxy0	proxy_segmean
proxy_coef	-0.0280	-0.0277	-0.0313
proxy_p	0.000	0.000	0.000
missing_term	-	proxy_miss	proxy_miss
missing_coef	-	0.0440	0.0463
missing_p	-	0.4077	0.3766

表 [17](#) (output data):

[4,2] proxy_sensitivity_comparison.csv

B.3 プロキシ変数の説明力

現在のデータではプロキシ変数の説明力は限定的だが、交互作用や特徴量の設計次第でセグメントとの複合的な効果が現れて誤差が低下する可能性は示唆される。

$$\epsilon_t^{occ} \sim P_{tot} + S(A) \quad (\text{付録 B.1})$$

$S(A)$ は A 基準を意味する。

$$\epsilon_t^{occ} \sim P_{tot} * S(A) \quad (\text{付録 B.2})$$

表 18: 回帰係数: セグメント付加 (付録 [B.1](#)) と交互作用 (付録 [B.2](#))

term	coef ₊	p ₊	coef _*	p _*
const	0.4007	0.0105	0.4427	0.0236
$S.B$	-0.2578	0.0139	-0.3618	0.0933
$S.C$	-0.1526	0.0704	0.4810	0.6856
P_{tot}	-0.0302	0.1357	-0.0364	0.1573
$P_{tot}:S.B$	-	-	0.0305	0.5194
$P_{tot}:S.C$	-	-	-0.0642	0.6081

表 [18](#) (output data):

[2,1] BM_proxy_total_segment_A.csv

表 19: proxy 特徴量と BM 誤差の相関. $P_{A,B,C}$ は各セグメント内の P_{tot}

proxy	n	pearson _r	pearson _p	spearman _r	spearman _p
P_A	7	-0.6394	0.1220	-0.8571	0.0137
P_B	6	-0.0648	0.9029	-0.2571	0.6228
P_C	2	-	-	-	-
P_{tot}	15	-0.0218	0.9386	-0.0964	0.7325
P_{re}	15	0.0703	0.8035	0.0107	0.9698
P_{sc}	15	-0.1295	0.6454	-0.0464	0.8695
P_{ca}	15	-0.0994	0.7246	-0.0036	0.9899

表 18 からは、セグメント A では P_{tot} が大きいほど BM 誤差が下がる傾向が見られる (P_{tot} 係数がどちらも負)、表 19 からも A の相関係数は負になっている。セグメント B では主効果と合わせた係数が -0.0059 とほぼゼロで、表 19 でも無相関となっている。これらはセグメントによって、プロキシの利き方が異なる可能性をしているが、交互作用によっても上乗せ効果は小さい ($R^2 = 0.702 \rightarrow 0.727$; segment 項なしの場合、 $R^2 = 0.001$, (付録 B.1) の場合 $R^2 = 0.702$, (付録 B.2) の場合 $R^2 = 0.727$ 。(表 22) (output data):

表 19 [2,1] proxy_BM.csv; [2,1] proxy_total_vs_BM.csv
表 22 [2,1] proxy_R2.csv

B.3.1 中心化プロキシ回帰

プロキシ特徴量 P_τ のセグメント内のばらつきを吸収するために、 P_τ が属するセグメント内の平均 $\bar{P}_\tau$ を引き去る操作をする (中心化)。

$$\mathcal{P}_\tau = P_\tau - \bar{P}_\tau, \quad P_\tau \in \text{Segment} \quad (\text{付録 B.3})$$

3 つのプロキシ変数 P_{re}, P_{sc}, P_{ca} だけでなく、 P_{tot} についても中心化し、以下を調べる:

$$\varepsilon_{task}^{occ} \sim P_{tot} + S(A) \quad (\text{付録 B.4})$$

$$\varepsilon_{task}^{occ} \sim P_{re} + P_{sc} + P_{ca} + S(A) \quad (\text{付録 B.5})$$

中心化によって相関係数の絶対値は上昇、p 値は減少する。p は依然として高く有意には至っていないが、説明力の増加傾向が見られる (表 20: output [2,3] centered_correlation_table.csv)

表 20: 中心化の効果: 相関表 19 の P_{tot} と P_{re}

proxy	n	pearson _r	pearson _p	spearman _r	spearman _p
P_{tot}	15	-0.0218	0.9386	-0.0964	0.7325
$\mathcal{P}_{tot}$	15	-0.265	0.3398	-0.4393	0.1014
P_{re}	15	0.0703	0.8035	0.0107	0.9698
$\mathcal{P}_{re}$	15	-0.134	0.6339	-0.2429	0.3831

表 21 (output data):

[2,3] centered_regression_components.csv

[2,3] centered_regression_proxy_total.csv

表 22 を見ると、交互作用や中心化の効果よりはむしろ、3 成分で詳細化するほうが説明力の上乗せ効果は大き

表 21: 回帰係数: 全体 proxy(付録 B.4) と 3 成分 (付録 B.5)

term	coef _t	p _t	coef ₃	p ₃
const	0.1954	0	0.1954	0
$S.B$	-0.1296	0.0059	-0.1296	0.0088
$S.C$	-0.2376	0.0012	-0.2376	0.0022
$\mathcal{P}_{tot}$	-0.0302	0.1357	-	-
$\mathcal{P}_{re}$	-	-	0.0070	0.6704
$\mathcal{P}_{sc}$	-	-	-0.0065	0.8556
$\mathcal{P}_{ca}$	-	-	-0.0388	0.2963

い ($R^2 = 0.702 \rightarrow 0.745$; segment 項なしの場合、 $R^2 = 0.001$, (付録 B.4) の場合 $R^2 = 0.702$, (付録 B.5) の場合 $R^2 = 0.745$.)

表 22: 説明力の比較

spec	R^2
P_{tot} only	0.0005
$P_{tot} + S$	0.7018
$\mathcal{P}_{tot} + S$	0.7018
$P_{tot} * S$	0.7265
$P_{re} + P_{sc} + P_{ca} + S$	0.745
$\mathcal{P}_{re} + \mathcal{P}_{sc} + \mathcal{P}_{ca} + S$	0.745

表 22 (output data):

[2,1] proxy_R2.csv; [2,3] centered_regression_r2.csv

付録 C 職業データとモデル一覧

C.1 職業データ一覧

表 23: このノートで一貫して用いる値。職業ごとの 3 タスク時間比率と重要度、時間削減率 (実績値) {ref.1, ref.2, ref.4} とその平均値 (BM)。実績値は文献 [1]-[7] からピックアップした。これらの測定実験の結果概要は Section 0、職業真値とタスク構成の方法は Section 1 に詳述した。

C.2 使用したモデル一覧

表 24: このノートで用いた LLM の一覧。使用したモデル名とその id、割り当てたセグメント。モデルの性能値は対応する OpenLM Chatbot Arena のモデル名とその性能値を紐づけている。これらは、Elo と誤差の関係を分析するのに用いている。

C.3 職業真値からの誤差

LLM の推論 (3 タスクの人間所要時間、AI 所要時間とそれの見積根拠) に基づいて計算した時間削減率を、時間比率による加重平均を求めたものを LLM 推定値とする場合の、職業真値からの誤差一覧。(C.3.1)

重要度を加味した時間加重平均の場合を C.3.2 に示す。

これらの表はモデルごとに存在するが、このノートでは 2 つの代表的なモデルのみ例示する。保守的な推論をしたセグメント C 群から 1 例 gpt51T (GPT-5.1 Thinking)

表 23: タスクの特徴：時間比率 w_t 、重要度 W_t 、削減率真値. ref.2 の職業 7,8 は [3],[7] の値

職業		1. 記事の要約		2. 指示書の作成		3. プレゼン作成		削減率（実績）			3 平均
		時間比率	重要度	時間比率	重要度	時間比率	重要度	ref.1	ref.2	ref.4	BM
1	経営コンサルタント	20%	0.7	40%	0.9	40%	0.9	42.2%	37%	83.5%	54%
2	事業企画（企画職）	15%	0.6	35%	0.8	50%	0.9	38.95%	37%	80%	52%
2.2	マーケティング担当	25%	0.7	20%	0.6	55%	0.8	40.2%	37%	87%	55%
3	プロジェクトマネージャー	10%	0.5	60%	0.9	30%	0.7	42%	37%	85%	55%
4	編集者／ライター	60%	0.9	20%	0.5	20%	0.4	55.6%	37%	91%	61%
5	営業アシスタント／秘書	30%	0.6	50%	0.8	20%	0.5	48.7%	-	66%	57%
6	研修／インストラクター	20%	0.5	20%	0.6	60%	0.9	38%	-	95%	67%
7	財務・経理系	45%	0.9	35%	1	20%	0.95	-	80%	80%	80%
7.2	財務・経理系	21%	0.82	43%	0.92	36%	0.88	43.3%	-	80%	62%
8	顧客サポート	40%	1	45%	0.95	15%	0.8	-	80%	56%	68%
8.2	顧客サポート	22%	0.72	44%	0.9	35%	0.84	43.7%	-	56%	50%

表 24: 使用したモデルと Chatbot Arena 指標の対応表

model id	使用モデル	segment	OpenLM モデル	Arena Elo	AAII	MMLU-Pro
gpt51T	GPT-5.1 Thinking	C	GPT-5.1-high	1464	70	87.1
gpt52P	GPT-5.2 Pro	C	GPT-5.2-high	1465	72	87.4
gpt52I	GPT-5.2 Instant	A	GPT-5.2	1464	68	87.4
gpt52T	GPT-5.2 Thinking	A	GPT-5.2-high	1465	72	87.4
sonnet46	Sonnet 4.6	A	Claude Sonnet 4.6	1446	65	87.3
sonnet46T	Sonnet4.6 Ext. Thinking	A	Claude Sonnet 4.6	1446	65	87.3
opus46	Opus 4.6	A	Claude Opus 4.6	1490	71	89.5
opus46T	Opus 4.6 Ext. Thinking	A	Claude Opus 4.6 Thinking	1503	73	89.7
haiku45	Haiku 4.5	A	Claude Haiku 4.5	1378	42	80
gpt35t	GPT-3.5-turbo-0125	B	GPT-3.5-turbo-0613	1145	9	46.2
gpt4om	GPT-4o-mini-2024-07-18	B	GPT-4o-mini-2024-07-18	1289	22	64.8
gem2:9b	Gemma2-9b	B	Gemma2-9b-it	1213	8	49.5
llama32:3b	Llama3.2-3b	B	Llama3.2-3b-instruct	1118	5	34.7
mist:7b	Mistral-7b-ins-v02	B	Mistral-7b-inst-v02	1097	1	24.5
llama2:13b	Llama2-13b-chat	B	Llama2-13b-chat	1093	6	40.6

と、先進的な推論をしたセグメント A 群から 1 例 haiku45 (Claude Haiku 4.5) を示す。

全てのモデルのデータは以下に収められている。
raw data (output text from LLMs) は
[2,1] in_proxy_new
解析用に整形されたデータ (input data) は
[0] Time_Weighted_Average_Data_W.csv
[0] Importance_Weighted_Average_Data_W.csv

C.3.1 時間加重平均の場合

保守的なセグメント C 群から 1 例 gpt51T (GPT-5.1 Thinking) を表 25 に、セグメント A 群から 1 例 haiku45 (Claude Haiku 4.5) を表 26 に示す。

C.3.2 重要度時間加重平均の場合

保守的なセグメント C 群から 1 例 (gpt51T; GPT-5.1 Thinking) を表 27 に、セグメント A 群から 1 例 (haiku45; Claude Haiku 4.5) を表 28 に示す。

C.4 モデルごとの時間削減率

全職業の平均をとり、言語モデルごとの削減率と参照値からの乖離をまとめた。時間加重平均 (表 29) と重要度付時間加重平均 (表 30) のそれぞれを表にしている。

表 29(時間加重削減率) では、C 群 (gpt51T と gpt52P) が、A 群や B 群 (gpt35t, gpt4om, gem2:9b, llama32:3b, mist:7b, llama2:13b) に比べて、BM 参照の誤差が小さい (gem2:9b は例外的に同等)。一方、ref4 真値に関しては A 群の誤差が小さい。

表 30(重要度付時間加重削減率) では、A 群の誤差が改善

表 25: 削減率推定値の偏差と乖離率 (GPT-5.1 Thinking)

職業 occ	削減率 1	削減率 2	削減率 3	加重平均	BM	ref.4	ε_1	χ_1	ε_2	χ_2
1 経営コンサルタント	75%	60%	50%	59%	54%	84%	5%	9%	-25%	-29%
2 事業企画（企画職）	75%	63%	50%	60%	52%	80%	8%	15%	-20%	-25%
2.2 マーケティング担当	75%	69%	68%	70%	55%	87%	15%	27%	-17%	-20%
3 プロジェクトマネージャー	75%	57%	50%	58%	55%	85%	3%	6%	-27%	-32%
4 編集者／ライター	71%	61%	50%	59%	61%	91%	-2%	-4%	-32%	-35%
5 営業アシスタント／秘書	75%	64%	50%	61%	57%	66%	3%	6%	-5%	-8%
6 研修／インストラクター	71%	58%	50%	58%	67%	95%	-9%	-13%	-37%	-39%
7 財務・経理系	67%	58%	50%	57%	80%	80%	-23%	-29%	-23%	-29%
7.2 財務・経理系	67%	58%	50%	57%	62%	80%	-5%	-8%	-23%	-29%
8 顧客サポート	60%	60%	70%	64%	68%	56%	-4%	-6%	8%	14%
8.2 顧客サポート	70%	60%	56%	61%	50%	56%	11%	21%	4%	8%

表 26: 削減率推定値の偏差と乖離率 (Haiku4.5)

職業 occ	削減率 1	削減率 2	削減率 3	加重平均	BM	ref.4	ε_1	χ_1	ε_2	χ_2
1 経営コンサルタント	94%	92%	92%	93%	54%	84%	38%	71%	9%	11%
2 事業企画（企画職）	94%	92%	92%	92%	52%	80%	40%	77%	12%	15%
2.2 マーケティング担当	94%	93%	92%	93%	55%	87%	38%	69%	6%	7%
3 プロジェクトマネージャー	93%	91%	91%	92%	55%	85%	37%	67%	7%	8%
4 編集者／ライター	94%	91%	90%	91%	61%	91%	30%	49%	0%	0%
5 営業アシスタント／秘書	94%	92%	93%	92%	57%	66%	35%	61%	26%	40%
6 研修／インストラクター	94%	92%	92%	92%	67%	95%	26%	39%	-3%	-3%
7 財務・経理系	96%	92%	96%	95%	80%	80%	15%	18%	15%	18%
7.2 財務・経理系	94%	91%	91%	92%	62%	80%	30%	49%	12%	15%
8 顧客サポート	97%	95%	95%	96%	68%	56%	28%	40%	40%	71%
8.2 顧客サポート	93%	91%	90%	91%	50%	56%	41%	83%	35%	63%

表 27: 削減率推定値の偏差と乖離率 (重要度加重：GPT-5.1 Thinking)

職業 occ	削減率 1	削減率 2	削減率 3	加重平均	BM	ref.4	ε_1	χ_1	ε_2	χ_2
1 経営コンサルタント	53%	54%	45%	50%	54%	84%	-4%	-8%	-33%	-40%
2 事業企画（企画職）	45%	50%	45%	47%	52%	80%	-5%	-10%	-33%	-41%
2.2 マーケティング担当	53%	41%	55%	49%	55%	87%	-6%	-11%	-38%	-44%
3 プロジェクトマネージャー	38%	51%	35%	42%	55%	85%	-13%	-23%	-43%	-51%
4 編集者／ライター	64%	31%	20%	33%	61%	91%	-28%	-46%	-58%	-64%
5 営業アシスタント／秘書	45%	51%	25%	40%	57%	66%	-18%	-31%	-26%	-40%
6 研修／インストラクター	36%	35%	45%	39%	67%	95%	-27%	-41%	-56%	-59%
7 財務・経理系	60%	58%	48%	54%	80%	80%	-26%	-32%	-26%	-32%
7.2 財務・経理系	55%	54%	44%	50%	62%	80%	-12%	-19%	-30%	-38%
8 顧客サポート	60%	57%	56%	57%	68%	56%	-11%	-16%	1%	2%
8.2 顧客サポート	50%	54%	47%	51%	50%	56%	1%	1%	-5%	-10%

表 28: 削減率推定値の偏差と乖離率 (重要度加重 : Haiku4.5)

	職業 occ	削減率 1	削減率 2	削減率 3	加重平均	BM	ref.4	ε_1	χ_1	ε_2	χ_2
1	経営コンサルタント	66%	83%	83%	80%	54%	84%	25%	47%	-4%	-5%
2	事業企画 (企画職)	56%	73%	82%	74%	52%	80%	22%	42%	-6%	-8%
2.2	マーケティング担当	66%	56%	74%	65%	55%	87%	10%	19%	-22%	-25%
3	プロジェクトマネージャー	47%	82%	64%	68%	55%	85%	13%	24%	-17%	-20%
4	編集者/ライター	85%	46%	36%	50%	61%	91%	-12%	-19%	-41%	-45%
5	営業アシスタント/秘書	56%	73%	46%	59%	57%	66%	2%	3%	-7%	-10%
6	研修/インストラクター	47%	55%	83%	65%	67%	95%	-2%	-3%	-30%	-32%
7	財務・経理系	87%	92%	91%	91%	80%	80%	11%	13%	11%	13%
7.2	財務・経理系	77%	84%	80%	81%	62%	80%	19%	31%	1%	1%
8	顧客サポート	97%	91%	76%	86%	68%	56%	18%	26%	30%	54%
8.2	顧客サポート	67%	82%	76%	76%	50%	56%	27%	53%	20%	36%

し、BM 真値、ref4 真値ともに A 群の誤差が小さい。重要度が見積削減率を小さくする効果として働き、A 群や B 群の BM 参照誤差を小さくしている。

付録 D 資料

再現性を担保するため、以下 url で CSV 入力ファイル、python コード、出力結果を提供している。

https://github.com/pub5023/productivity_indicator

フォルダ構成

- 0 input data: Arena Elo data, モデルごとの時間見積データ, w_t , W_t データ
- 1 occ_truth_regression
 - 1.1 importance_regression: Elo と誤差の回帰分析 ($imp * T$)、モデル散布図
 - 1.2 segmented_regression: セグメント交互作用 ($imp * T * S, S + T$)
- 2 proxy_analysis
 - 2.1 proxy_preparation: キーワード辞書、判断理由データ、proxy 特徴量計算
 - 2.2 proxy_regression: proxy 回帰分析 ($P * S, P + S$)、中心化回帰
- 3 task_truth_decomposition
- 4 task_truth_regression: 回帰 ($S + T, P + T + S, imp * T + S$)、proxy 感度分析
- 5 appendix_occ_truth_results: 職業真値ベース回帰 ($S + T, P + T + S, imp * T + S$)

表 29: モデル比較：時間削減率、偏差、乖離率の平均値

model	削減率				BM		ref.4	
	要約書	指示書	プレゼン	時間加重	ε_1	χ_1	ε_2	χ_2
GPT-5.1 Thinking	71%	61%	54%	60%	8%	13%	20%	25%
GPT-5.2 Pro	63%	47%	50%	51%	9%	13%	27%	32%
GPT-5.2 Instant	85%	75%	75%	77%	18%	32%	10%	13%
GPT-5.2 Thinkng	84%	74%	74%	76%	17%	30%	10%	14%
Sonnet 4.6	87%	82%	75%	80%	18%	32%	10%	13%
Sonnet4.6 Ext. Thinking	90%	87%	80%	85%	25%	44%	9%	14%
Opus 4.6	78%	70%	69%	71%	13%	23%	13%	17%
Opus 4.6 Ext. Thinking	83%	76%	70%	75%	16%	29%	8%	10%
Haiku 4.5	94%	92%	92%	93%	33%	57%	15%	23%
GPT-3.5-turbo-0125	65%	64%	63%	64%	14%	24%	24%	31%
GPT-4o-mini-2024-07-18	80%	73%	70%	73%	14%	26%	12%	17%
Gemma2-9b	68%	61%	61%	63%	8%	14%	21%	26%
Llama3.2-3b	65%	63%	50%	58%	10%	17%	27%	33%
Mistral-7b-ins-v02	81%	80%	76%	79%	20%	35%	16%	22%
Llama2-13b-chat	68%	60%	55%	60%	21%	36%	25%	33%

表 30: モデル比較：時間削減率、偏差、乖離率の平均値 (重要度加重)

model	削減率				BM		ref.4	
	要約書	指示書	プレゼン	時間加重	ε_1	χ_1	ε_2	χ_2
GPT-5.1 Thinking	51%	49%	42%	47%	14%	22%	32%	38%
GPT-5.2 Pro	45%	39%	39%	40%	20%	33%	38%	47%
GPT-5.2 Instant	61%	61%	58%	60%	10%	16%	22%	27%
GPT-5.2 Thinkng	61%	60%	57%	59%	9%	15%	23%	28%
Sonnet 4.6	62%	66%	58%	62%	10%	18%	19%	23%
Sonnet4.6 Ext. Thinking	65%	70%	62%	66%	10%	19%	17%	21%
Opus 4.6	56%	57%	54%	55%	9%	14%	24%	29%
Opus 4.6 Ext. Thinking	59%	61%	55%	58%	9%	15%	22%	26%
Haiku 4.5	68%	74%	72%	72%	14%	25%	17%	23%
GPT-3.5-turbo-0125	46%	52%	49%	50%	13%	22%	32%	38%
GPT-4o-mini-2024-07-18	58%	59%	56%	57%	10%	17%	25%	30%
Gemma2-9b	48%	50%	49%	49%	12%	21%	31%	37%
Llama3.2-3b	49%	51%	40%	46%	17%	28%	33%	41%
Mistral-7b-ins-v02	59%	66%	60%	62%	14%	24%	24%	30%
Llama2-13b-chat	48%	48%	42%	46%	21%	36%	33%	41%

参考文献

- [1] B.S. Freeman et al., 2024. Evaluation of Task Specific Productivity Improvements Using a Generative Artificial Intelligence Personal Assistant Tool, arXiv.2409.14511[cs.HS]. <https://doi.org/10.48550/arXiv.2409.14511>.
- [2] S. Noy, W. Zhang, Experimental Evidence on the Productivity Effects of Generative AI, *Science*, 381(2023) 187-192. <https://doi.org/10.1126/science.adh2586>.
- [3] C. Jeong et al., 2025. E2E Process Automation Leveraging Generative AI and IDP-Based Automation Agent: A Case Study on Corporate Expense Processing, *Artificial Intelligence and Applications*. <https://doi.org/10.47852/bonviewAIA52026307>.
- [4] Anthropic Inc., Estimating AI productivity gains from Claude conversations. <https://www.anthropic.com/research/estimating-productivity-gains>, 2025 (accessed 16 April 2026).
- [5] Anthropic Inc., Anthropic Economic Index report: Economic primitives. <https://www.anthropic.com/research/anthropic-economic-index-january-2026-report>, 2026 (accessed 16 April 2026).
- [6] E. Brynjolfsson, D. Li, L.R. Raymond, 2023. Generative AI at Work, National Bureau of Economic Research, NBER Working Paper No. 31161. <https://doi.org/10.3386/w31161>.
- [7] R. Junquera et al., 2025. From Theory to Practice: A Strategic AI Integration Model for Revenue Administrations, *World Bank*. <https://doi.org/10.1596/43463>.
- [8] L. Zheng et al., Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena, *Advances in Neural Information Processing Systems* 36 (2023) 46595–46623. <https://doi.org/10.52202/075280-2020>.
- [9] W.-L. Chiang et al., Chatbot arena: an open platform for evaluating LLMs by human preference, *Proceedings of the 41st International Conference on Machine Learning* (2024) 8359–8388. <https://dl.acm.org/doi/abs/10.5555/3692070.3692401>.
- [10] P. Liang et al., Holistic Evaluation of Language Models, *Transactions on Machine Learning Research* 2023-August (2023). <https://doi.org/10.1111/nyas.15007>.
- [11] A. Jacovi, Y. Goldberg, Towards Faithfully Interpretable NLP Systems: How Should We Define and Evaluate Faithfulness?, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (2020) 4198–4205. <https://doi.org/10.18653/v1/2020.acl-main.386>.
- [12] M. Turpin et al., Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting, *Advances in Neural Information Processing Systems* 36 (2023) 74952–74965. <https://doi.org/10.52202/075280-3275>.